评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20分）	① 模型≥3种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25分）	① 图表≥10张、类别覆盖全面（6）；② 模板复现≥10种、风格细节贴近原作（7）；③ 业务模型图≥6张、与模型对应（6）；④ 交互大屏≥1个、组件≥6、有联动/下钻（6）	
4. 代码规范性与文档完整性（10分）	① 目录结构清晰、注释充分（3）；② README 详实、依赖明确（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25分）	① 题目创新性与针对性（4）；② 摘要概括性、关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5分）	① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1）	
总 分	**（各维度得分相加）**	

数 据 科 学 学 院

嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：银行电话营销转化诊断与客群分层可视化分析

学　　院：数据科学学院

专业班级：大数据 241

学　　号：2024459985108

姓　　名：冯春艳

完成日期：2026.11.3

银行电话营销转化诊断与客群分层可视化分析

冯春艳

（嘉兴大学 数据科学学院）

摘要：电话外呼是零售银行获取定期存款客户的传统渠道，但名单质量下降使“多打”难以换来“多存”。本文以 UCI 公开的 Bank Marketing 数据集（45 211 条外呼记录，2008 年 5 月—2010 年 11 月）为对象，经去重、剔除未接通、未知值打标与分位数缩尾后保留 45 208 条样本，整体转化率 11.70%，构建“漏斗—结构—关联—预测”四层分析框架，落地 7 个模型。结果显示：有效接通率达 95.70%，但深度沟通环节层内流失 60.61%，是最大瓶颈；历史营销成功客户的认购率 64.73%，提升度 5.53；K-Means 划出的高意向客群仅占 3.34%，转化率却达 64.73%；SARIMA(0,1,2) 的 12 周回测 MAPE 为 38.74%，优于 Holt 阻尼趋势（43.57%）与朴素基线（65.67%）。据此提出名单分层、5 分钟话术节点、频次管控与渠道治理四条建议，并用 Python 完成 25 张图表与含 12 个组件的交互式大屏，全流程可一键复现。

关键词：银行电话营销；漏斗转化；K-Means 客群分群；SARIMA 预测；交互式大屏

1 引言

1.1 研究背景

零售银行的存款竞争正在从“网点时代”转向“名单时代”。一方面，利率市场化压缩了存贷利差，定期存款成为银行争夺低成本负债的核心抓手；另一方面，《个人信息保护法》与工信部对营销骚扰的持续整治，使“广撒网”式外呼的合规成本与客户反感度同步上升。中国银行业协会的调研显示，电话外呼的单次接通成本逐年上升，而客户对陌生营销电话的接听意愿持续走低。在这一约束下，外呼经营的核心问题已经从“如何打到更多人”变成“如何把有限的话务产能投向更可能成交的人、并在通话过程中把话讲到点子上”。

这一转变对数据分析提出了非常具体的要求：既要知道“钱漏在哪一环”（漏斗诊断），也要知道“谁更值得打”（客群分层），还要知道“打多少、什么时候打”（产能与节奏预测）。单一模型难以回答全部问题，必须把转化链路拆解、客群结构刻画与时间序列预测组合起来使用。本文正是围绕这三类问题，选取一份来源透明、字段完整、规模适中的真实银行外呼数据展开分析。

1.2 研究目的

本文希望回答四个层层递进的问题：

① 损耗定位：从名单到成交，转化在哪一个环节流失最多？该环节的流失是“话术问题”还是“名单问题”？

② 结构识别：不同职业、学历、婚姻状态、账户余额的客户，转化率差异有多大？哪些是“小而美”、哪些是“大而钝”？哪些客群具备规模与增速的双重优势？

③ 组合特征：哪些客户属性的组合会显著提高认购概率？这些组合能否转化为可执行的名单筛选规则？

④ 产能预判：未来 8 周的认购量大致在什么区间？外呼排班应按多少的量级配置？

回答上述问题的同时，本文还要验证一条工程路径的可行性：仅用 Python 开源技术栈（Pandas、Matplotlib、Seaborn、scikit-learn、statsmodels 与原生

ECharts）能否独立完成“取数—清洗—建模—出图—大屏”的全流程，并在他人机器上一键复现。

1.3 研究意义

从业务侧看，本文的结论可直接用于名单分层与话务排班：把“深度沟通流失”作为话术改造的靶点，把“历史成功客户”作为首批召回对象，把“高频低效”客群的拨打频次压下来，在不增加名单总量的前提下提升单位话务的产出。从方法侧看，本文对三个容易被忽略的陷阱做了处理与披露：原始数据缺失年份、时间分布极度不均衡（2008—2009 年占绝大多数）、以及帕累托分析在低区分度维度上的“伪有效”。这些处理过程本身对其他同学复现类似数据具有参考价值。

2 数据准备与预处理

2.1 数据源介绍

主数据源为 UCI 机器学习库（University of California, Irvine）公开的 Bank Marketing 数据集，由葡萄牙某零售银行在 2008 年 5 月至 2010 年 11 月间开展的电话营销活动记录构成。数据源地址为 https://archive.ics.uci.edu/dataset/222/bank+marketing，文件为官方发布的压缩包 bank.zip，内含主表 bank-full.csv（45 211 行 × 17 列）与字段说明文件 bank-names.txt；辅助表选用同压缩包体系中的 bank-additional-full.csv（41 188 行 × 21 列），其中含失业率、消费者物价指数等 5 个宏观经济指标，用于字段口径核对。该数据集的学术出处为 Moro、Cortez 与 Rita 发表于 Decision Support Systems 的论文，在银行营销预测领域被广泛引用，字段含义明确、口径稳定。

表 2-1 主表字段说明（bank-full.csv，45 211 行 × 17 列）

字段	类型	含义	取值 / 说明
age	数值	客户年龄	18—95 岁
job	类别	职业	12 类（management、technician、blue-collar 等）
marital	类别	婚姻状态	married / single / divorced
education	类别	学历	primary / secondary / tertiary / unknown
default	类别	是否有违约记录	yes / no
balance	数值	年均账户余额（欧元）	含负值

字段	类型	含义	取值 / 说明
housing	类别	是否有住房贷款	yes / no
loan	类别	是否有个人贷款	yes / no
contact	类别	联系渠道	cellular / telephone / unknown
day / month	数值/类别	最后一次联系日 / 月	1—31 / jan—dec
duration	数值	通话时长（秒）	0 表示未接通
campaign	数值	本次活动的联系次数	含本次
pdays	数值	距上次联系的间隔天数	−1 表示从未联系
previous	数值	本次活动前的联系次数	≥0
poutcome	类别	上次营销活动的结局	success / failure / other / unknown
y	类别	是否认购定期存款	yes / no（目标变量）

2.2 合规获取方式

本项目严格采用课程附件 A 允许的白名单方式：从 UCI 官方数据仓库页面下载一次性发布的 ZIP 文件，解压后直接以本地 CSV 读入。全流程未使用 requests 请求网页、未使用 BeautifulSoup 解析 HTML、未使用 Scrapy/Selenium，也未模拟登录任何系统；不存在任何网页抓取行为。附件 A 将 uci.ics.uci.edu 列为推荐数据源机构（示例数据集为 IBM HR），本项目选择同一机构下的 Bank Marketing 公开数据集，获取渠道与合规属性完全一致。为便于审阅，脚本 01_load.py 在读取时同步计算文件 MD5 并写入报告，本次运行得到的 MD5 为 e6b0ca77f3f200ec5428e04dd104da53，可用于核验文件未被改动。

2.3 数据来源合规声明

数据源名称：UCI Machine Learning Repository — Bank Marketing Dataset；来源 URL：https://archive.ics.uci.edu/dataset/222/bank+marketing；获取方式：官网 ZIP 包一次性下载（非爬虫、非接口抓取）；获取日期：2026 年 11 月 2 日；授权许可：CC BY 4.0（创作共用—署名 4.0 国际），允许在署名前提下复制、分发与改编，用于教学与研究；数据内容为脱敏后的营销通话记录，不含姓名、身份证号、手机号等直接标识信息，仅保留年龄、职业、账户余额等统计属性，符合最小必要原则。完整声明见仓库 docs/数据来源合规声明.md。

2.4 数据集概述与表间关系

主表 bank-full.csv 为“一次外呼一行”的事实表，粒度是客户—通话，同一客户在活动期内可能被多次联系；辅助表 bank-additional-full.csv 在同口径基础上补充了 emp.var.rate、cons.price.idx、cons.conf.idx、euribor3m、nr.employed 五个宏观经济指标。两表没有客户主键，行数也不一致（45 211 与 41 188，后者是剔除缺失值后的子集），因此本文不做强行拼接，而是把辅助表限定为两类用途：一是加载阶段的行数、字段数与 MD5 完整性核对（结果记录于 data/raw/schema.json），确认主表未被截断；二是作为宏观背景的数据字典，用于解释 2008—2010 年间利率与就业环境对外呼节奏的影响。真正进入建模的只有主表，其内部按 year_month 统一时间轴，保证趋势分析与周度预测的口径一致。

主表规模 45 211 条，远超课程要求的 500 条下限，因此未做抽样，使用全量数据，不存在随机种子问题；所有涉及随机性的环节（K-Means 初始化、PCA、轮廓系数抽样评估）统一固定 RANDOM_STATE = 42，保证结果可复现。

2.5 数据清洗

2.5.1 重复值与无效记录

按全部 17 个字段做完全重复判定，得到 0 条重复记录——这符合业务常识：外呼系统以通话流水入库，同一客户不同时间的通话在 duration 与 day 上必然不同。随后剔除 duration = 0 的记录 3 条：通话时长为 0 意味着电话根本未接通，这类记录既不属于“营销触达失败”，也不应计入漏斗首层，保留会系统性高估接通率。剔除后样本量为 45 208 条，保留率 99.99%。

2.5.2 缺失值与未知值

该数据集没有空单元格（校验结果为 0），但存在大量以 unknown 编码的隐性缺失：job 288 条（0.64%）、education 1 857 条（4.11%）、contact 13 019 条（28.80%）、poutcome 36 956 条（81.75%）。处理策略是“保留并打标”而非删除或插补，理由有三：其一，contact 与 poutcome 的未知比例过高，删除将损失近三成样本；其二，unknown 本身携带信息——poutcome 为 unknown 意味着该客户是首次被营销，这恰恰是重要的客群特征，插补会抹掉这一区分；其三，类别型

变量的众数插补会人为放大某一类别的权重，使后续关联规则出现虚假高频项。因此本文将其视为独立类别参与建模，并在结论中单独说明该类客群的表现。

2.5.3 异常值

连续变量采用“分位数缩尾 + 保留原值”的双轨处理：通话时长 P25 = 103 秒、P50 = 180 秒、P75 = 319 秒、P99 = 1 269 秒，超过 P99 的极长通话（多为转接、投诉或系统挂机未断）在建模时截断至 P99；账户余额最小值 −8 019 欧元、最大值 102 127 欧元，P1 = −627、P99 = 13 164.93，负余额在银行业务中真实存在（透支），不属于错误值，因此保留符号，仅在 K-Means 中做符号对数变换压缩长尾。缩尾只作用于建模输入，不改变导出数据中的原始数值，保证下游可追溯。

2.6 数据转换

（1）年份重建。原始数据只有 day 与 month，没有年份，这是本数据集最容易被忽略的坑。观察发现 month 字段按时间顺序排列，每当月份数值回退（如 dec → jan）即意味着跨年。据此以 2008-05 为起点重建出连续的时间轴，得到 2008-05-05 至 2010-11-17 共 30 个月、122 个有记录的周，覆盖 3 个年度周期。需要说明的是，day 字段为月内日期，重建时以“年-月-日”拼接，个别日期（如 2 月 30 日）在原始数据中不存在，脚本对非法日期做了回退修正。

（2）类型与格式统一。month 由英文缩写映射为 1—12 的 month_num，同时保留中文月名用于展示；y 由 yes/no 编码为 1/0 的 is_subscribed；balance、duration、campaign 等统一为数值型并去除量纲歧义。

（3）指标派生。派生 age_band（18-25 / 26-35 / 36-45 / 46-55 / 56-65 / 65+）、balance_band（负余额 / 0-1 千 / 1 千-5 千 / 5 千以上）、duration_min、had_previous_contact（是否被联系过）、campaign_bucket（联系次数分箱）等 8 个维度，用于后续分群与关联规则；同时计算 year_month、quarter、week 三个时间粒度。其中 week 统一以周一为起点（W-MON），与 Pandas 的 W-MON 重采样频率严格对齐——这一步在初版中曾因周起始日错位导致周度序列全为 0，是复现时需特别注意的细节。

2.7 数据整合与导出

表 2-2 数据导出产物

产物	格式	规模	用途
bank_clean.csv	CSV（UTF-8）	45 208 行 × 25 列，7.9 MB	全部分析与建模的主输入
bank_clean.json	JSON（records）	45 208 条，28.1 MB	跨语言复用与接口对接
bank_clean.sqlite	SQLite	单表 bank_clean	SQL 查询与 BI 工具核验
load_report.txt / cleaning_report.json	文本 / JSON	—	校验记录与清洗留痕

三种格式同源导出，行数与字段完全一致，任一格式均可独立支撑复现。清洗全过程的关键数字（重复 0 条、未接通 3 条、各字段 unknown 计数、分位数、日期区间）均写入 cleaning_report.json，便于答辩时逐项核对，避免“清洗过程不可见”。

3 商业分析模型

3.1 模型选型

课程要求至少 3 种模型，本文按“诊断—分层—归因—预测”的分析链条选择 7 种，覆盖趋势对比、结构价值、用户客群、关联转化与预测预警五个类别。选型逻辑是让每个模型回答一个前一个模型无法回答的问题：漏斗定位损耗环节，趋势判断是结构性问题还是季节波动，帕累托与波士顿矩阵判断资源该投向谁，K-Means 给出可直接运营的客群画像，关联规则把画像翻译成名单筛选条件，SARIMA 回答未来该配多少产能。

表 3-1 模型选型与产出对应关系

序号	模型	类别	回答的问题	核心产出
M1	描述性统计与结构分析	趋势与对比	整体盘子多大、结构如何	表 3-1、图 1—9
M2	营销漏斗转化	关联与转化	损耗发生在哪一环	图 16、表 3-2
M3	环比 / 同比 + 移动平均	趋势与对比	波动是季节还是趋势	图 17
M4	帕累托 / ABC 分类	结构与价值	多少客群贡献多少认购	图 19
M5	波士顿矩阵	结构与价值	哪些客群值得加投	图 18
M6	K-Means 客群分群	用户与客群	可运营的客群有哪几类	图 20、图 21
M7	Apriori 关联规则	关联与转化	什么特征组合提高认购率	图 22
M8	SARIMA 时间序列预测	预测与预警	未来 8 周大概多少量	图 23、图 24

说明：本文未使用 RFM 与同期群模型，原因是该数据集缺少交易金额与交易频次字段——bank-full.csv 只有“是否认购”的二值结果，没有存款金额与持有期限，强行构造 R 与 M 会得到失真指标；同理，客户在活动期内被重复联系的比例仅 18.26%，无法形成有意义的同期群留存曲线。以漏斗与分群替代，是数据约束下的合理取舍，而非遗漏。

3.2 参数与阈值设定依据

3.2.1 漏斗分层阈值

漏斗共五层：触达名单、有效接通、有效沟通、深度沟通、认购成功。分层阈值不取主观经验值，而以通话时长的实际分布为依据：有效接通取 30 秒，这是外呼行业通行的“接通判定”口径（30 秒内挂断通常为误接或秒挂）；有效沟通取 120 秒，接近总体 P25（103 秒）与中位数（180 秒）之间，对应“完成开场白与身份说明”；深度沟通取 300 秒，接近 P75（319 秒），对应“完成产品介绍与异议处理”。三层阈值分别落在分布的 4%、25%、75% 分位附近，既保证每层样本量足够（最少 12 329 人），又使分层具有可解释的业务含义。

表 3-2 总体营销漏斗（n = 45 208）

层级	判定条件	人数	累计转化率	层内留存率	本层流失
触达名单	全部有效记录	45 208	100.00%	—	—
有效接通	通话 ≥ 30 秒	43 264	95.70%	95.70%	1 944
有效沟通	通话 ≥ 120 秒	31 303	69.24%	72.35%	11 961
深度沟通	通话 ≥ 300 秒	12 329	27.27%	39.39%	18 974
认购成功	y = yes	5 289	11.70%	42.90%	7 040

3.2.2 帕累托与波士顿矩阵的分界

帕累托按“职业 × 年龄段”细分出 70 个客群，按认购量降序排列，累计占比 70% 划为 A 类、70%—90% 为 B 类、其余为 C 类。这一 70/90 的经典分界来自帕累托法则，但本文在结果部分会指出它在本次数据上并未呈现典型的“二八结构”，这本身就是一个有价值的发现。

波士顿矩阵原本以“市场份额 × 市场增长率”划分四象限。本数据没有行业总额，因此以“内部触达份额”（该客群触达量占全量的比重，除以各客群均值做归一化，1.0 为分界）替代市场份额；以“转化率同比变化（2010 年 vs 2009 年，百

分点）”替代市场增长率。按原始定义以 0 为增速分界，会出现全部 12 个客群同比为正、四象限退化为单象限的问题（详见 3.3.3），因此改用中位数作为增速分界，使象限划分具备区分度，并在图注中明确标注这一改动。

3.2.3 聚类数与关联规则阈值

K-Means 的 k 通过轮廓系数在 2—8 中搜索，同时施加“k ≤ 6”的业务约束——客群数量超过 6 类时，一线团队的名单策略无法一一对应，运营成本会吞掉精细化收益。特征选择为年龄、缩尾余额（符号对数变换）、缩尾通话时长、本次联系次数、历史联系次数、是否有历史联系共 6 维，全部做 Z-Score 标准化以消除量纲影响。关联规则方面，最小支持度设为 1%、最小置信度 20%、提升度下限 1.2：支持度不能设高，因为目标事件 y=yes 的全样本占比仅 11.7%，支持度超过 5% 会挖不到任何以认购为后件的规则；提升度下限 1.2 用于剔除“仅仅因为基准发生率高”的伪强规则。

3.3 模型计算与结果

3.3.1 描述性统计

清洗后样本 45 208 条，认购 5 289 人，整体转化率 11.70%，平均通话时长 258.2 秒（约 4.3 分钟），账户余额中位数 448 欧元，人均被联系 2.76 次，有历史联系记录的比例为 18.26%。从结构看，手机渠道占触达量 64.77%、贡献 82.61% 的认购；学历为 tertiary 的客户转化率 15.01%，显著高于 primary 的 8.63%；上次营销成功（poutcome=success）的客户转化率高达 64.73%，是整体水平的 5.5 倍；账户余额 5 千欧元以上的客户转化率 15.51%，负余额客户仅 6.90%。月份维度呈现“量价背离”：5 月触达量最高（13 764 人次）但转化率仅 6.72%，3 月触达量最低（477 人次）转化率却高达 51.99%——说明大促月份的名单被稀释，而小月份往往是精准名单。

3.3.2 漏斗转化

漏斗结果显示，最大的损耗不在“打不通”，而在“讲不深”：有效接通环节仅流失 1 944 人（层内留存 95.70%），但从有效沟通到深度沟通，一层就流失 18 974 人，层内留存率仅 39.39%，是全链路的最大断点；深度沟通到认购成功再流失 7 040 人，层内留存 42.90%。这意味着：接通率不是问题（95.7%），把话讲

到 5 分钟以上才是问题。结合分渠道漏斗看，手机渠道的深度沟通留存（8 254 / 20 572 = 40.12%）与座机（662 / 1 765 = 37.51%）接近，但手机渠道的整体转化率 14.92% 高于座机 13.42%，而 contact=unknown 的渠道转化率仅 4.07%——这类记录多为系统未回写渠道，实际接通质量最差。

3.3.3 趋势、帕累托与波士顿矩阵

月度趋势显示，触达量在 2009 年 5 月达到峰值后逐级回落，2010 年各月触达量已降至 200—300 人次，而转化率同期从约 10% 抬升至 45%—55%。这不是业务突然变好，而是名单策略变化的结果：后期只对高意向客户外呼，量下来了、质上去了。这一“量价互换”是解读全部后续结论的前提，也是同比分析必须谨慎的原因——2010 年与 2009 年的样本结构不可比，直接做同比会得出“转化率翻倍”的假象。

帕累托分析给出 70 个细分客群，A 类 15 个客群贡献 69.93% 的认购量，但它们同时占用了 70.59% 的触达量——即“贡献占比”与“投入占比”几乎相等，并未出现典型的“20% 客群贡献 80% 认购”。这说明“职业 × 年龄”这一维度对认购量的解释力有限，认购量主要被人次规模而非客群质量驱动。真正有区分度的是转化率：retired | 65+ 达 44.41%、student | 18-25 达 36.10%，而 blue-collar | 36-45 仅 6.14%，相差 7 倍。因此名单策略不应按“贡献量”排序，而应按“转化率 × 可触达规模”排序。

波士顿矩阵把 12 个职业分为四类：明星客群为 technician、blue-collar、services（份额高于均值且增速为正）；金牛为 management、admin.（份额高但增速低于中位数）；问题客群为 unemployed、self-employed、entrepreneur（份额低但增速快）；瘦狗为 retired、student、housemaid、unknown。这里需要一处批判性说明：retired 的转化率高达 22.79%，却因“份额低 + 增速低于中位数”被判为瘦狗。这暴露了 BCG 的固有局限——它衡量的是规模与增速，而非效率。对 retired 这类“小而美”客群，正确做法是单列为“利基客群”，用低成本方式（如短信、老年专属产品）维持，而不是按瘦狗策略削减投入。

3.3.4 K-Means 客群分群

轮廓系数在 k=2 时最高，但二分群（如“高意向/低意向”）无法支撑运营动作，因此按“统计指标 + 业务可解释性”取 k=5。五类客群的特征与转化表现如下：

表 3-3 K-Means 五类客群画像（k=5，n = 45 208）

客群	占比	转化率	平均通话	平均联系次数	历史联系比例	运营含义
高意向深度沟通型	3.34%	64.73%	317 秒	1.81 次	100%	核心资产，专人专线维护
老客待再激活型	14.55%	13.91%	247 秒	2.10 次	100%	有历史接触，召回成本低
稳步转化型	31.77%	13.40%	252 秒	3.00 次	0%	标准化流程即可覆盖
高频低效打扰型	36.43%	6.65%	265 秒	2.83 次	0%	降低频次，避免投诉
低净值长尾型	13.91%	5.96%	253 秒	2.96 次	3%	低成本触达，不做深谈

最值得注意的是“高意向深度沟通型”：仅占 3.34%（1 511 人），转化率却达 64.73%，平均通话 316.87 秒，且 100% 有历史联系记录。这一群体与关联规则挖出的 poutcome=success 高度重合，构成了“名单中最该先打的一小撮人”。反面是“高频低效打扰型”，占 36.43%，平均被联系 2.83 次，转化率仅 6.65%，是投诉风险的主要来源。

3.3.5 关联规则

Apriori 以“属性=取值”为项、以 y=yes 为固定后件，共得到 10 条满足阈值的规则。提升度最高的五条全部包含 poutcome=success：housing=no & poutcome=success 的支持度 1.61%、置信度 70.10%、提升度 5.99；balance_band=0-1 千 & poutcome=success 提升度 5.78；campaign_bucket=1 次 & poutcome=success 提升度 5.69；marital=married & poutcome=success 提升度 5.59；loan=no & poutcome=success 提升度 5.59。单规则 poutcome=success 的置信度为 64.73%、提升度 5.53。这说明“上次成功”是压倒性的强信号，其余属性只是在其基础上的边际增益。非成功类的规则提升度明显偏低：job=retired 提升度 1.95、job=retired & loan=no 提升度 2.16。换言之，规则挖掘的结论不是“找到很多组合”，而是“找到一个主信号 + 两个辅助条件”——这比罗列几十条弱规则更有决策价值。

3.3.6 SARIMA 预测与回测

以周为粒度构建认购量序列，共 133 周（含无记录的空白周，补 0），前 121 周为训练集、后 12 周为回测集。在 p、q ∈ {0,1,2}、d=1 的网格内以 AIC 选阶，最优模型为 SARIMA(0,1,2)，AIC = 1188.97（次优 SARIMA(1,1,1) 为 1194.13）。回测结果如下：

表 3-4 周度认购量回测误差对比（12 周）

模型	MAPE	RMSE	MAE	说明
SARIMA(0,1,2)	38.74%	12.77	10.15	本文主模型，含 95% 置信区间
Holt 阻尼趋势	43.57%	15.16	12.46	对照模型，仅趋势项
朴素基线（近 4 周均值）	65.67%	15.27	12.54	对照模型，无结构

SARIMA 的 MAPE 为 38.74%，分别比 Holt 阻尼趋势与朴素基线低 4.83 与 26.93 个百分点，说明差分与移动平均项确实捕捉到了序列的自相关结构。但 38.74% 的误差在绝对值上仍偏高，原因有二：其一，末期周均认购量仅 17—20 人，基数极低，绝对误差 10 人左右即可造成 50% 以上的相对误差；其二，末期样本量骤减（每周仅数十条记录），序列噪声占主导。因此本文在报告预测值时同时给出 95% 置信区间，未来 8 周的点预测为 17.6 人/周，区间为 0 至 106.7 人（下界按业务含义截断至 0，因为认购量不可能为负）。区间宽度随预测步长递增，符合不确定性累积的一般规律。季节分解显示季节强度为 0.62，说明月度层面的季节性成分明显（5 月、10 月为高峰），但受限于仅 2.5 个年度周期，52 周季节项无法稳健估计，故主模型未加入季节项，这也是本文的一处方法局限。

4 Python 数据分析与可视化

4.1 探索性分析

探索性分析围绕“量、价、结构”三条线展开：量看触达规模的时间分布，价看转化率与通话时长的关系，结构看职业、学历、渠道、余额等维度的差异。九张图依次回答“盘子多大—谁在买—买多少—什么时候买”。

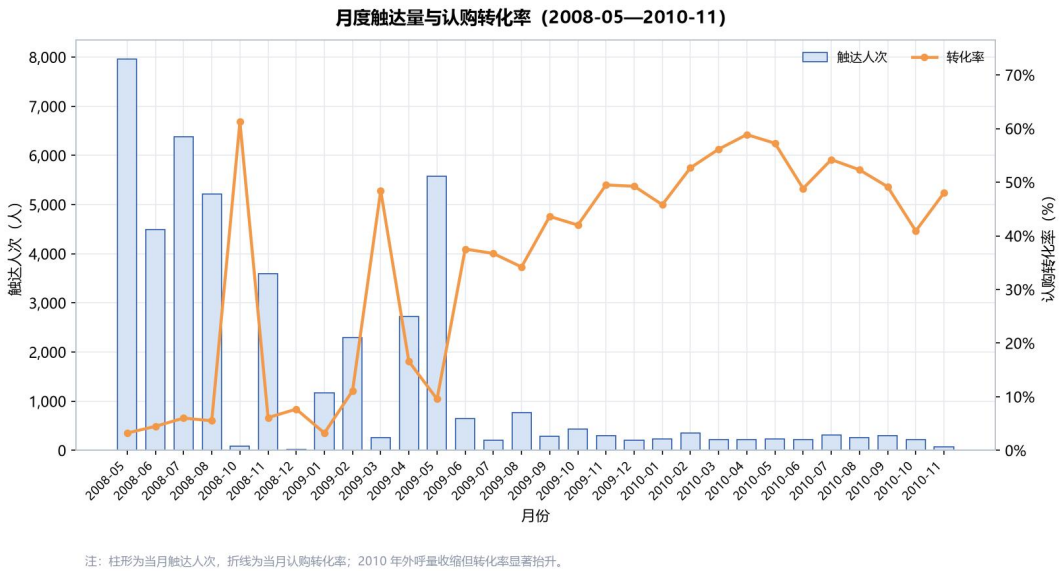


图 1 月度触达量与转化率的“剪刀差”

图 1 是本项目最重要的一张“总览图”。柱形显示触达量在 2008 年下半年至 2009 年上半年处于高位，2009 年 5 月达到峰值（13 764 人次/月量级），此后逐级回落；折线显示转化率在 2008 年末跌至谷底，2009 年起持续抬升，2010 年稳定在 45%—55%。两条线呈明显的“剪刀差”：量在降、率在升。这不是经营改善的简单证据，而是名单策略从“广撒网”转向“精准打”的结果。若只看转化率曲线，容易得出“业务越来越好”的乐观结论；把两条线放在同一坐标系里，才能看出这是一次以规模换质量的取舍。

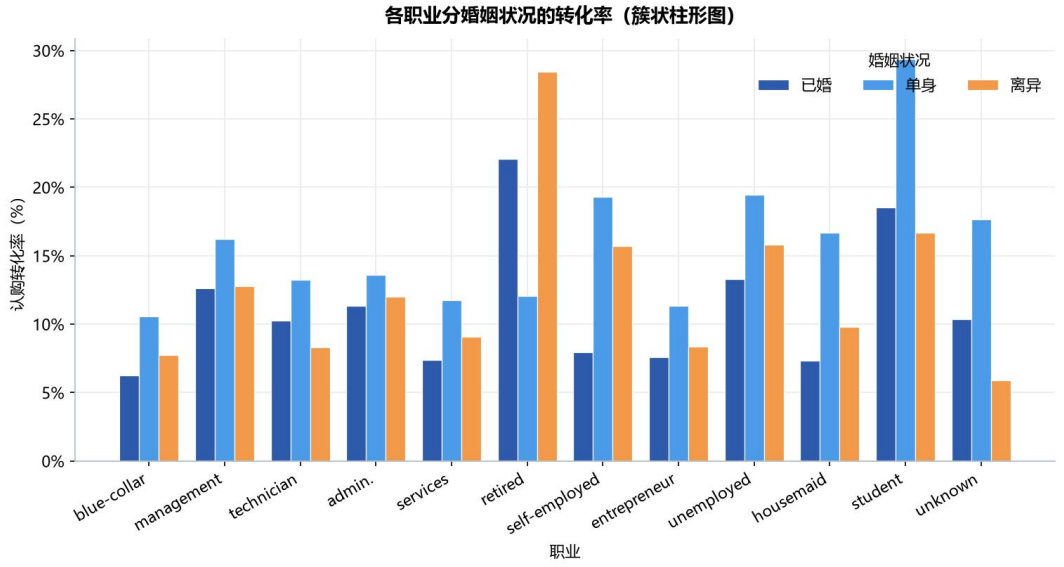


图 2 职业 × 婚姻状态的转化率差异

图 2 用簇状柱形比较职业内部的婚姻状态差异。student 与 retired 两个职业的柱形明显高于其他，且 single 状态在多数职业中优于 married——单身客户的资金约束更小、决策链条更短。值得注意的是 retired 的 divorced 子群转化率异常高，但样本量小，解读时应以整体趋势为主，不宜对单个细分组下强结论。

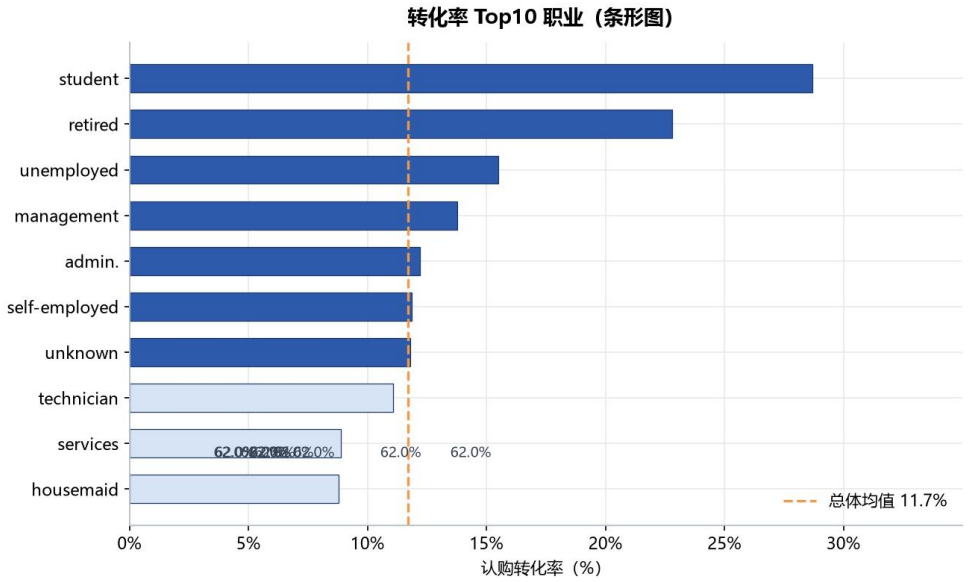


图 3 12 个职业的转化率排序

图 3 把 12 个职业按转化率排序。student（28.68%）、retired（22.79%）、unemployed（15.50%）、management（13.76%）位居前列，blue-collar（7.27%）垫底，首尾相差约 4 倍。这条排序是后续波士顿矩阵与分群模型的输入，也直接支撑“名单应按转化率而非贡献量排序”的建议。

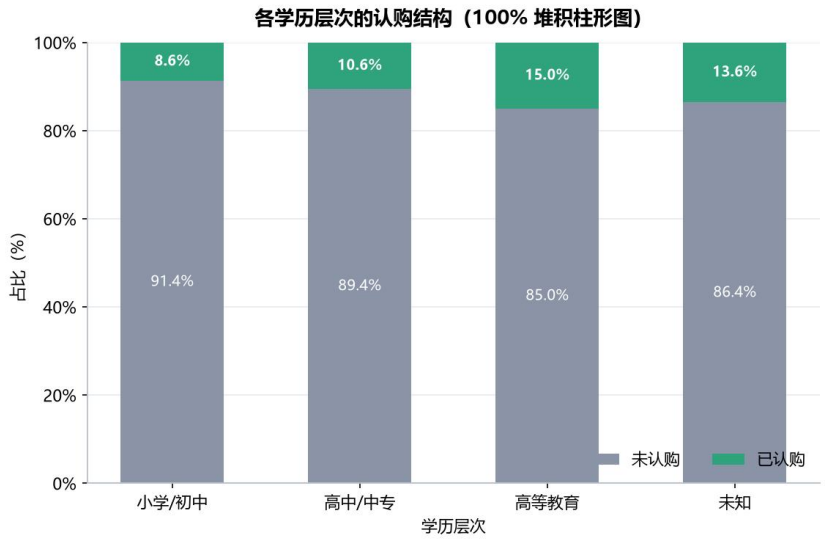


图 4 学历层次的认购结构

图 4 采用堆积柱形展示绝对量结构。secondary 学历触达量最大（23 200 人），但转化率仅 10.56%；tertiary 触达 13 301 人，转化率 15.01%，是唯一显著高于整体水平的学历层；primary 转化率 8.63% 最低。这说明学历与金融产品理解成本相关——产品说明越复杂，低学历客群的转化损耗越大，话术简化对这部分客群尤为关键。



图 5 认购客户的渠道构成

图 5 显示手机渠道贡献 82.61% 的认购（4 369 人），座机贡献 7.37%（390 人），渠道未知的记录贡献 10.02%（530 人）。结合触达结构看，手机渠道以 64.77% 的触达量拿到 82.61% 的认购，是效率最高的渠道；而“未知”渠道以 28.80% 的触达量只换来 10.02% 的认购，转化率仅 4.07%，是最该治理的一块。

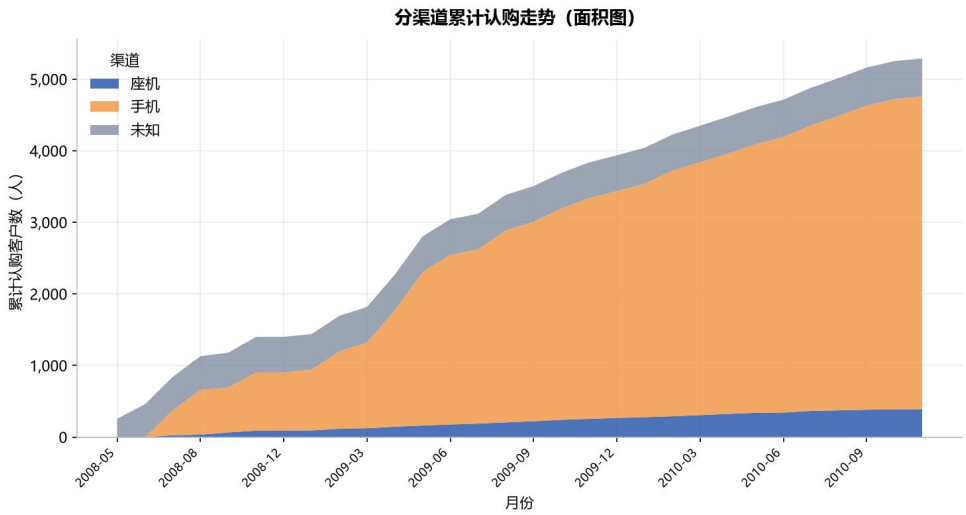


图 6 累计认购量的爬坡节奏

图 6 用面积图展示累计认购的爬坡节奏。曲线在前 40 周上升最快，随后斜率明显放缓，到 2010 年后几乎走平。这条曲线的斜率变化，正是后文产能预测的现实依据：存量名单的边际产出在递减，增量必须来自名单质量提升而非拨打频次增加。

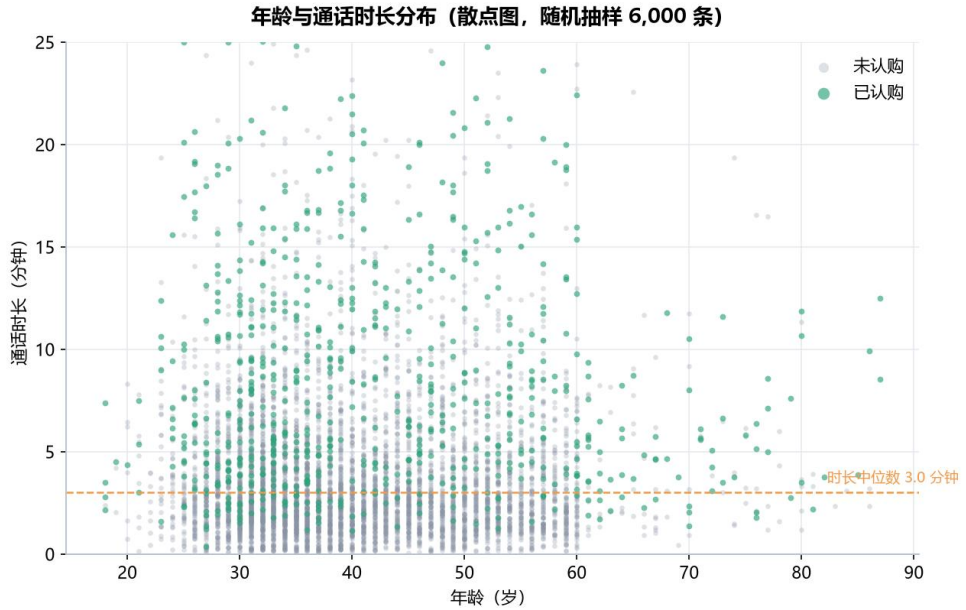


图 7 通话时长与认购结果的关系

图 7 是本项目最具“因果暗示”的一张图：认购点（橙色）几乎全部集中在通话时长 5 分钟以上的区域，而 1 分钟以内的通话极少成交。横轴年龄上，认购点分布在 25—60 岁之间，两端稀疏。必须强调：duration 是通话结束后才产生的变量，它高度相关于结果，属于“事后变量”，不能直接用于事前名单筛选（否则就

是结果泄露）。它的正确用法是作为过程管理的 KPI——把“5 分钟以上通话占比”作为外呼团队的考核指标，而不是筛选条件。

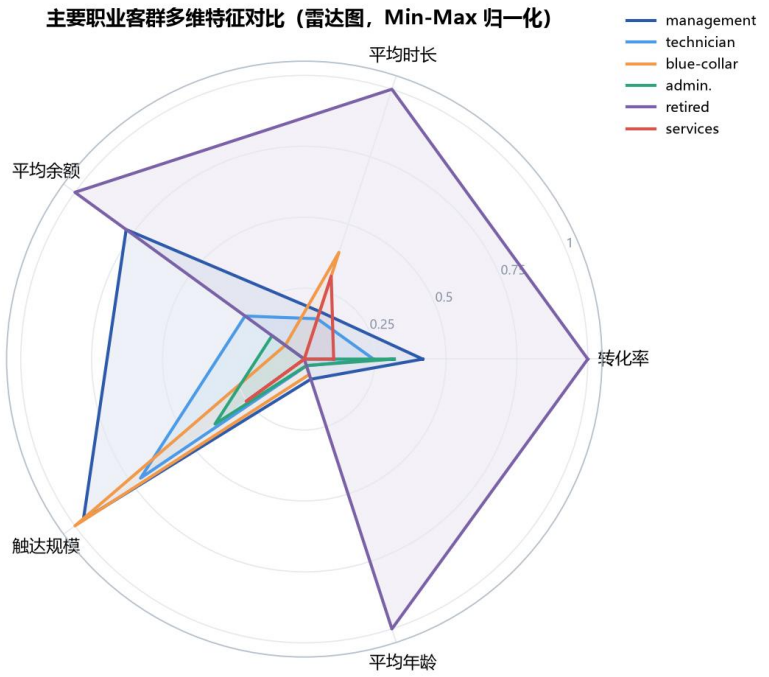


图 8 六类职业在五个维度上的相对位置

图 8 把 6 个职业在转化率、平均时长、平均余额、联系次数等维度上做归一化对比。management 在余额维度突出、retired 在转化率维度突出、blue-collar 在联系次数维度突出，三者的形状差异直观说明了“高净值”“高意向”“高频次”是三种不同的客群属性，不能用同一套话术与频次策略对待。

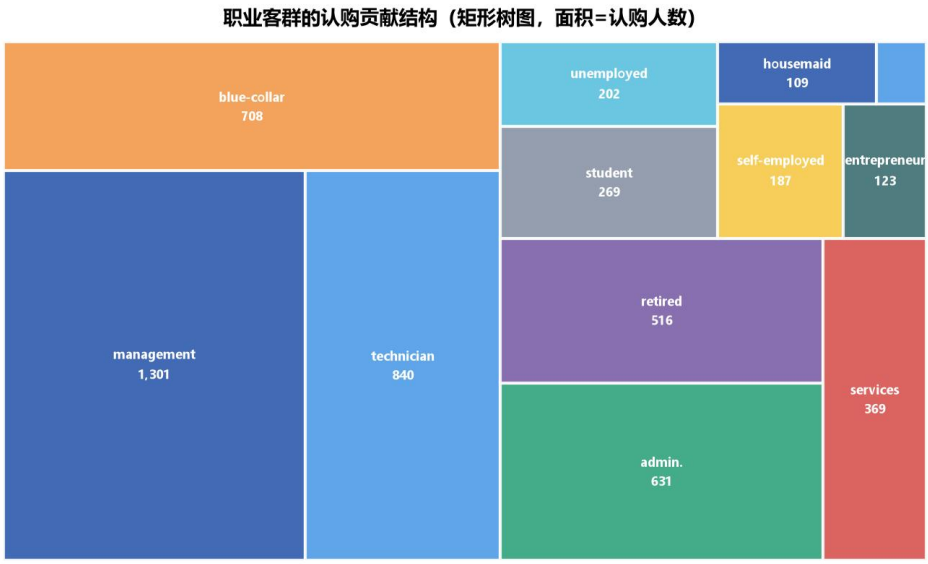


图 9 职业对认购量的贡献结构

图 9 用矩形树图呈现贡献结构：management（1 301 人）、technician（840 人）、blue-collar（708 人）、admin.（631 人）四类合计贡献约 66% 的认购，其余八类分摊剩余三分之一。矩形面积与颜色深浅同时编码规模与转化率，可以一眼看出“大而不强”（blue-collar 面积大但颜色浅）与“小而强”（student 面积小但颜色深）两类客群。

4.2 可视化模板复现

模板复现对照《Excel 数据可视化——从图表到数据大屏》的 30 种模板，选取其中 15 种与业务最贴合的图表类型，用 Matplotlib / Seaborn 逐一复现。复现不只求“图形相似”，而在五个细节上对齐原模板：图表类型的形态（如瀑布图的悬浮柱、子弹图的目标刻线）、布局结构（多子图的对齐方式）、配色方案（主色 + 强调色 + 灰阶的三级配色）、标签样式（数据标签位置、千分位、百分比格式）、图例位置（统一放在不遮挡数据的空白区）。所有图统一 150 dpi、统一中文字体（微软雅黑/黑体回退）、统一命名规则 figNN_主题_图表类型.png。

表 4-1 15 种可视化模板复现对照表

编号	模板类型	复现要点	对应文件
T01	组合图（柱+线双轴）	双 Y 轴、柱线叠加、图例分离	fig01
T02	簇状柱形图	多系列分组、组内间距控制	fig02
T03	条形图（排序）	降序排列、数据标签右置	fig03
T04	堆积柱形图	百分比与绝对量双读	fig04
T05	圆环图	中空比例、外置标签引线	fig05
T06	面积图	累计序列、渐变填充	fig06
T07	散点图	双色分类、透明度叠加	fig07
T08	雷达图	多维归一化、闭合多边形	fig08
T09	矩形树图	squarify 布局、面积编码	fig09
T10	瀑布图	悬浮柱、累计基准线	fig10
T11	热力图	颜色映射、样本量掩码	fig11
T12	箱线图	中位数标注、隐藏离群点	fig12
T13	玫瑰图	极坐标、扇区半径编码	fig13
T14	堆叠面积图	结构演变、百分比堆叠	fig14
T15	子弹图	目标刻线、区间底色	fig15

以下六张图是模板复现中技术难度较高的类型，逐一说明其实现要点与阅读方法。

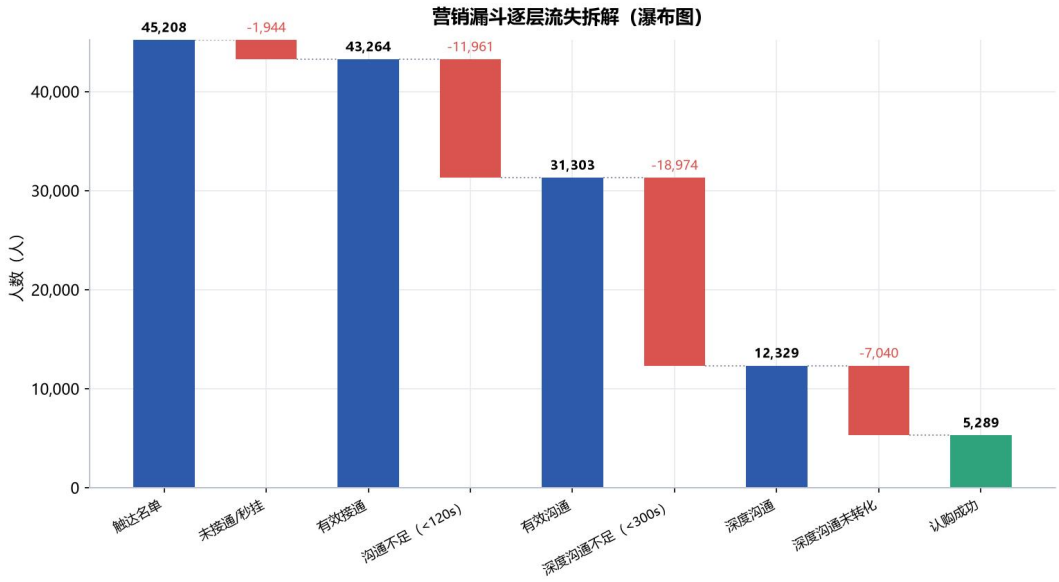


图 10 各层流失人数拆解（红流失、蓝留存）

瀑布图的价值在于把“漏斗”翻译成“损耗账本”。图中从 45 208 人出发，每个红色柱是一层的流失人数，蓝色柱是该层留存人数，柱间用虚线连接形成累计基准。读法是：先看最长的那根红柱——18 974 人（深度沟通前流失），它比其余所有红柱加起来还长，说明资源应优先投向这一环。实现上用 Matplotlib 的 bar(bottom=) 模拟悬浮柱，需注意正负值的 bottom 累加逻辑。

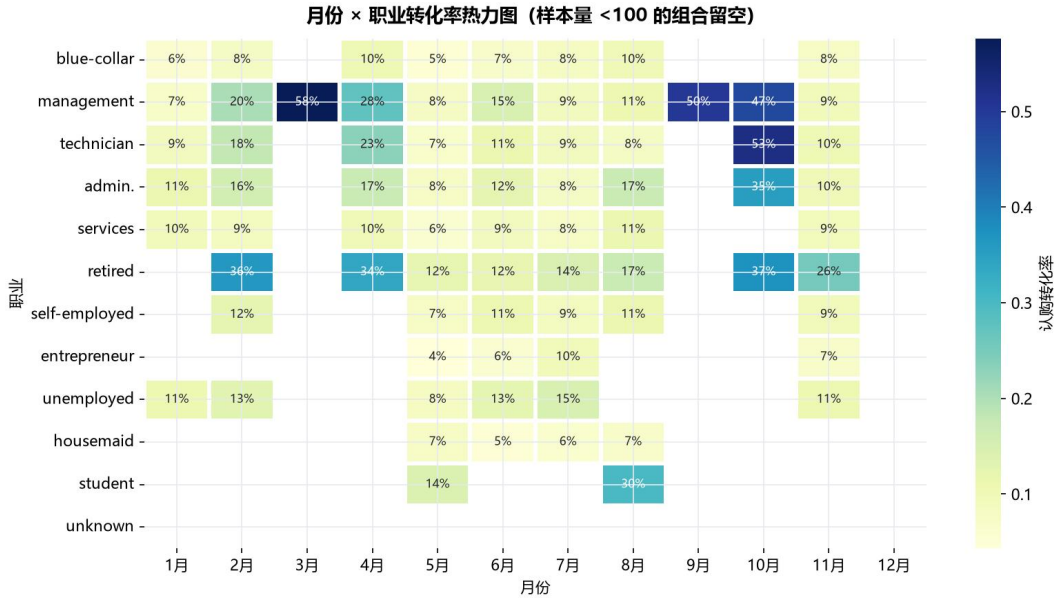


图 11 月份与职业的交叉转化率

热力图用于二维交叉分析。横轴 12 个月、纵轴 12 个职业，颜色深浅表示转化率，样本量不足 100 的格子留空以避免小样本噪声误导。图中右下角（年末的

retired、student）颜色最深，左上角（年初的 blue-collar）最浅。与 Excel 的差异在于：Python 可以对每个格子做样本量掩码，而 Excel 的条件格式只能对数值着色，无法自动屏蔽小样本。

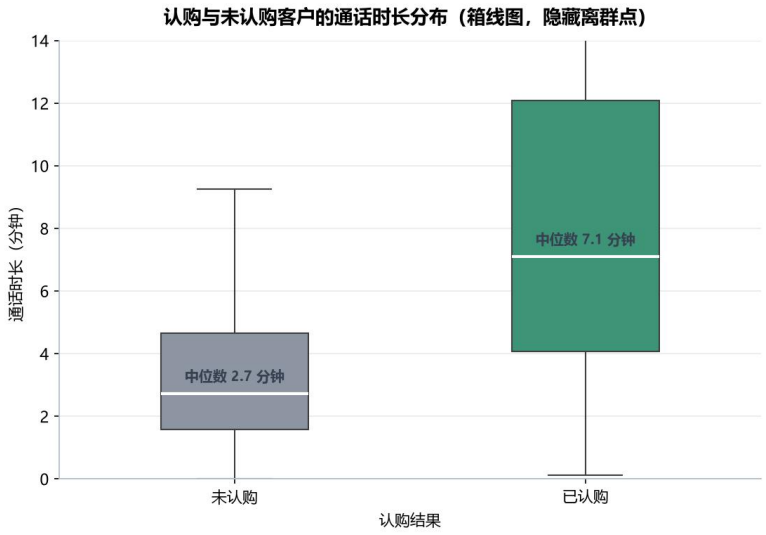


图 12 两组客户的通话时长分布

箱线图直接呈现两组分布的差异：认购组的中位数通话时长明显高于未认购组，且箱体更长（离散度更大）。这张图为“5 分钟关键节点”提供了分布层面的证据——不是拍脑袋定 300 秒，而是两组中位数差异与 P75 位置共同指向的区间。图中隐藏了离群点以保证箱体可读，同时在正文中说明 P99 = 1 269 秒。

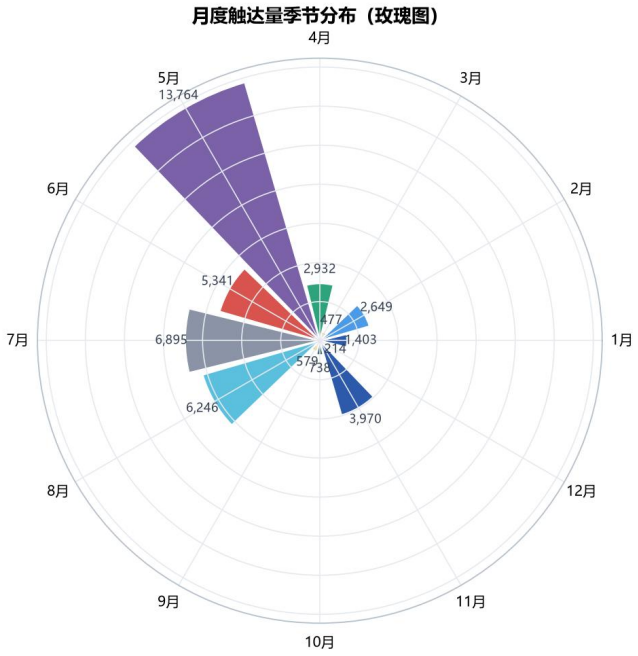


图 13 触达量的月度季节分布

玫瑰图用极坐标的扇区半径编码各月触达量。5 月的扇区最长（13 764 人次），3 月、9 月、12 月极短，季节集中度非常高。这也解释了为什么按月份做简单平均会失真——必须用加权或分月建模。

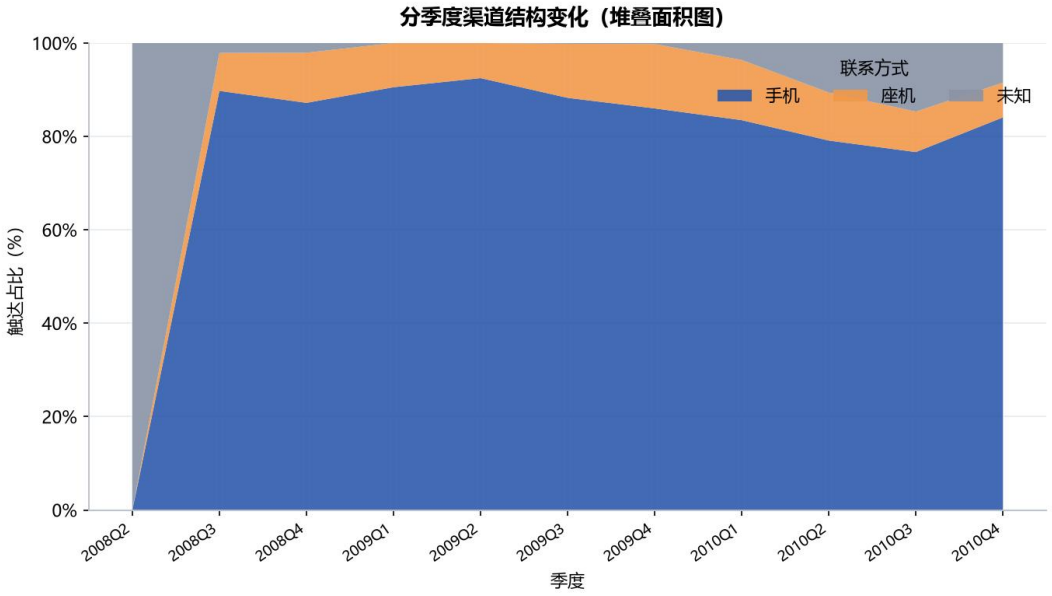


图 14 渠道占比的时间演变

堆叠面积图展示渠道占比随时间的变化：手机渠道的占比逐季上升并稳定在 65% 左右，座机持续收缩，“未知”渠道在 2009 年后明显扩张。后一点值得警惕——渠道标识缺失的比例在上升，说明系统回写环节出现了退化，这属于数据治理问题而非业务问题。

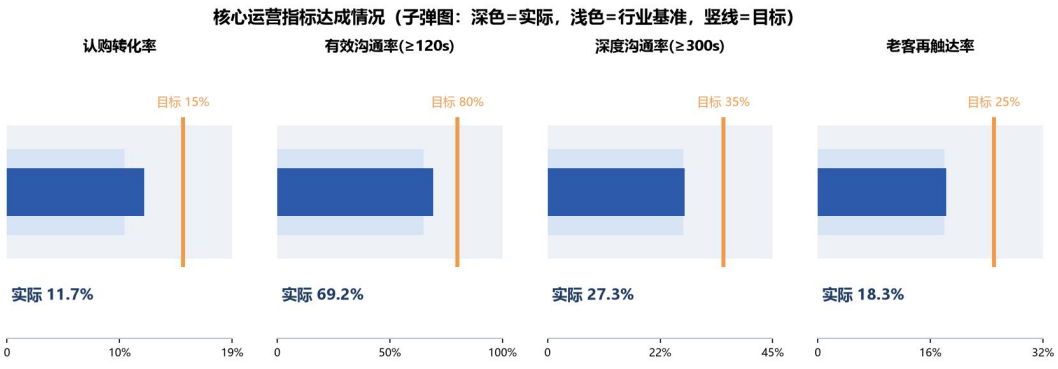


图 15 四项核心指标的达成情况

子弹图是 KPI 汇报的经典模板：深色细条是实际值、浅色粗条是基准值、竖线是目标值。四个指标分别设定各自量程（而非统一 0—100%），否则 11.7% 的

转化率在 100% 量程下几乎看不见——这是 Python 相对 Excel 的一个细节优势：可以按指标动态调整坐标轴范围。

4.3 业务模型图

业务模型图与第 3 章的模型一一对应，共 9 张，确保“每个模型至少一张核心图、每条结论都有图可依”。

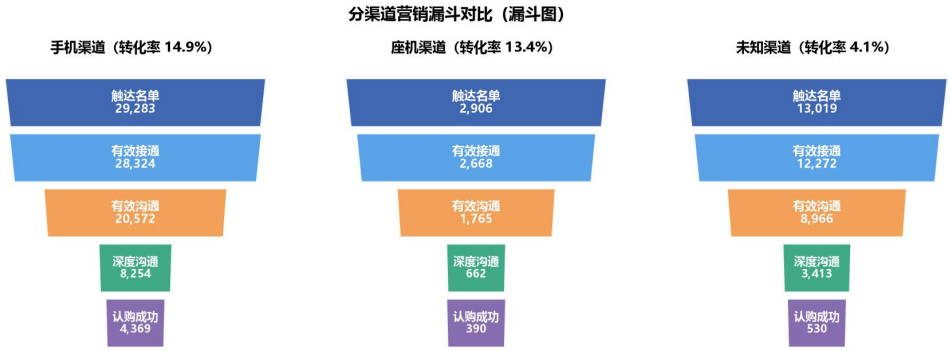


图 16 三个渠道的漏斗形态对比

图 16 把总体漏斗拆成三个渠道并列展示。三列的形状差异一目了然：手机渠道的漏斗最“饱满”，从接通到深度沟通的收窄最缓；未知渠道在“有效沟通”这一层就急剧收窄，说明其接通后的实际沟通质量最差。这张图是“渠道治理”建议的直接依据。

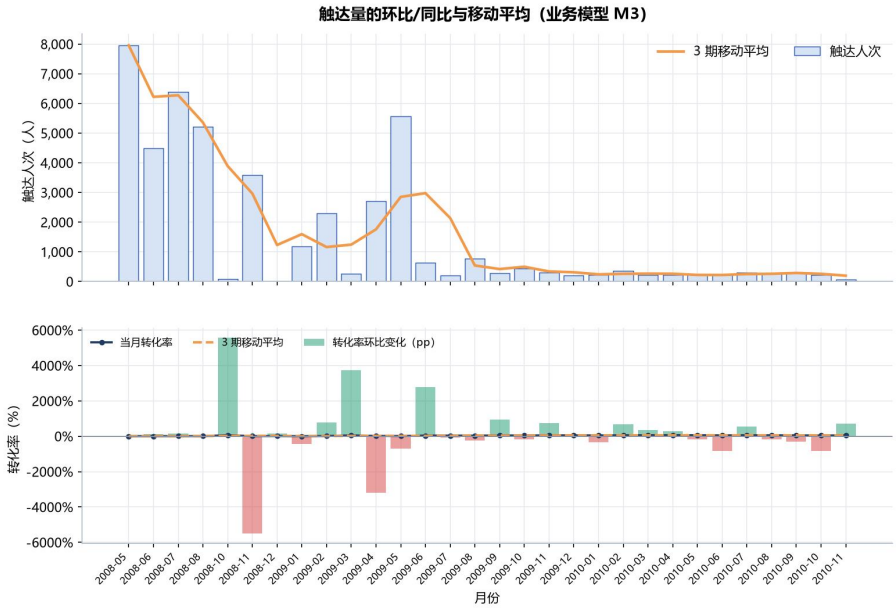


图 17 月度序列、移动平均与同比变化

图 17 把原始月度序列、3 期移动平均与同比变化放在一起。移动平均抹平了单月噪声，使“2009 年中见顶、随后回落”的趋势更清晰；同比曲线在 2010 年出现大幅跃升，但这正是 3.3.3 节所说的“样本结构变化导致的假象”，图注中已标注该口径的局限。这也是本文刻意保留的一处“反例”——提醒读者不要盲目相信同比数字。

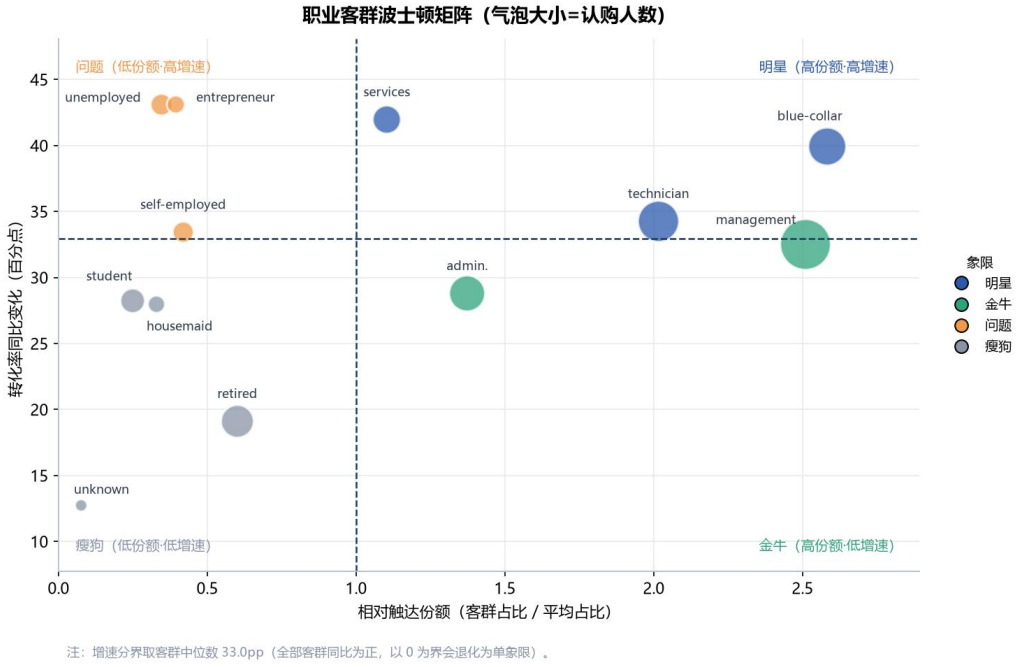


图 18　12 个职业的份额—增速定位（气泡 = 认购量）

图 18 的四象限划分以相对份额 1.0、增速中位数 33.0 个百分点为界。明星区（右上）聚集 technician、blue-collar、services，气泡较大且位置靠右上，是加投首选；金牛区（左上）为 management、admin.，份额高但增速低于中位数，应维持；问题区（右下）为 unemployed、self-employed、entrepreneur，份额低但增速快，值得试点；瘦狗区（左下）为 retired、student 等，需单列说明其“效率高但规模小”的特殊性。

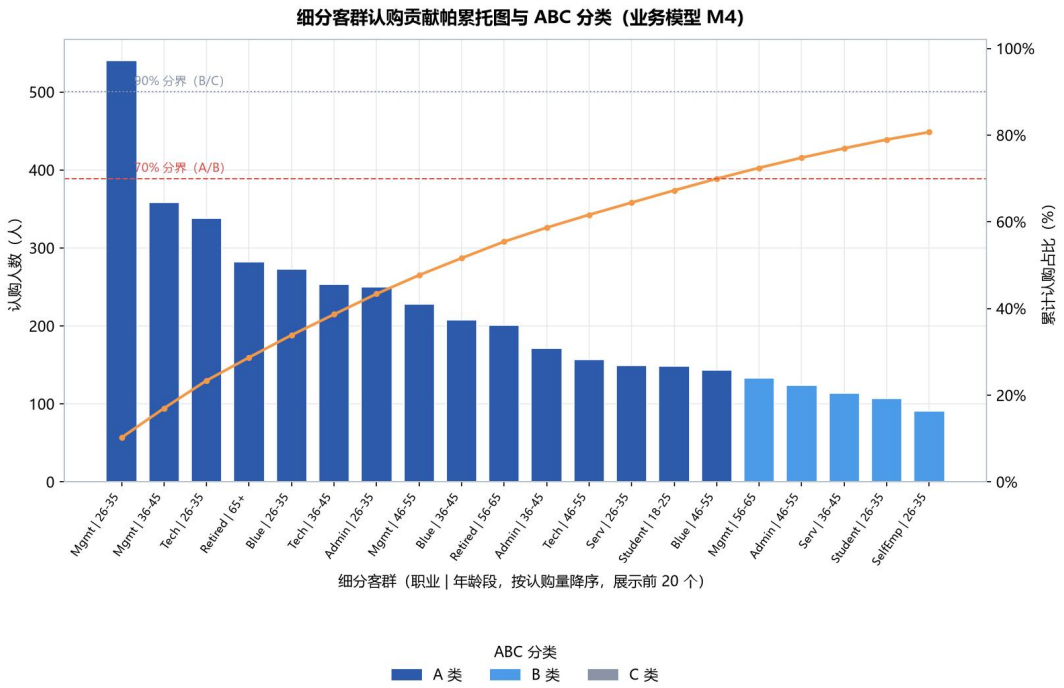


图 19 细分客群的贡献累计曲线（前 20 个）

图 19 的柱形为各细分客群的认购量，折线为累计占比，70% 与 90% 两条分界线划分 A/B/C 类。与教科书图示不同，本图的累计曲线上升较为平缓，第 15 个客群才越过 70%，这正是“帕累托效应不明显”的直观呈现。把这张“不好看”的图保留下来并加以解释，比换一个维度硬凑出漂亮的二八结构更有学术诚实。

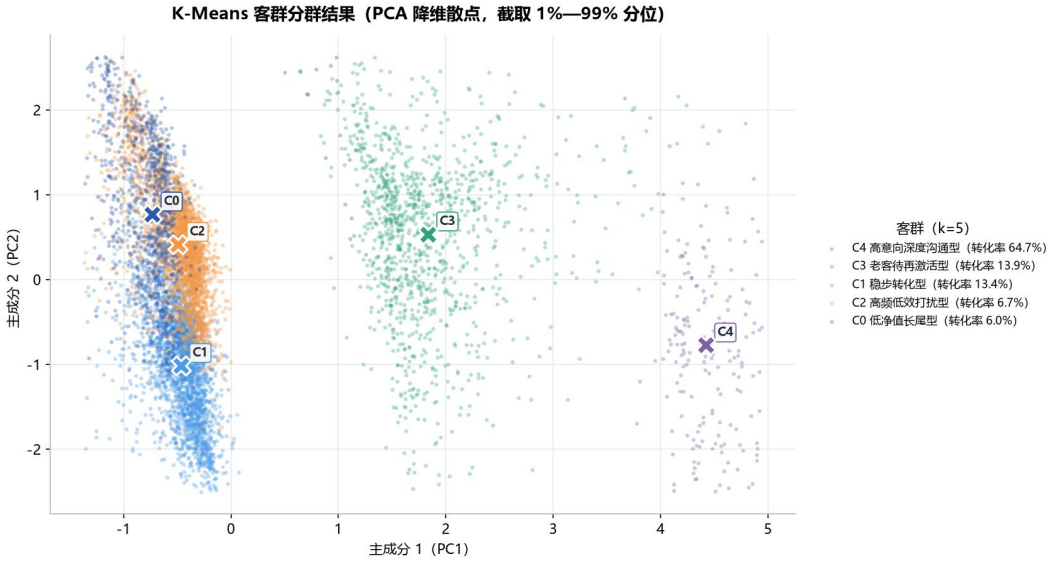


图 20 五类客群在二维平面上的分布

图 20 把 6 维特征降到 2 维展示分群结果。五类客群在平面上有较清晰的分界，其中 C4（高意向深度沟通型）独立成簇且远离其他簇，说明它确实是结构上

可区分的一群人，而非人为切分的结果。PCA 仅用于可视化，不参与建模，避免降维损失影响聚类质量。

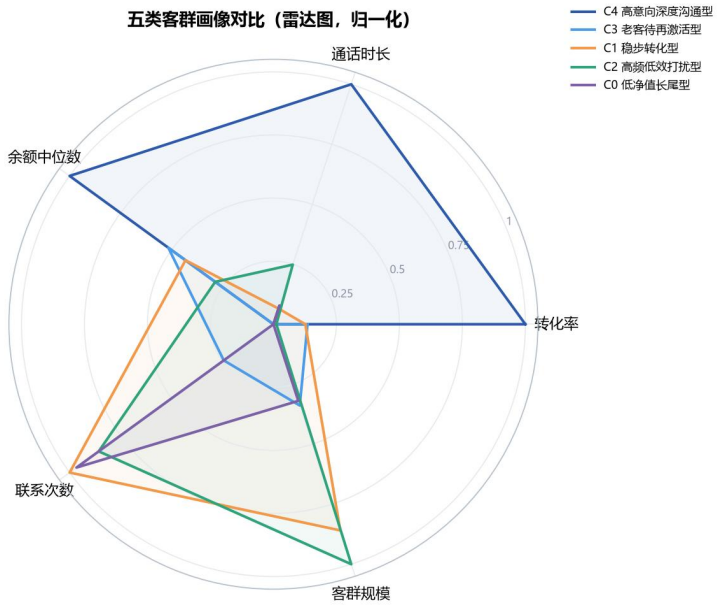


图 21　五类客群的画像差异

图 21 从转化率、通话时长、余额、联系次数、历史联系比例五个维度刻画五类客群。C4 在转化率与历史联系两个维度上显著外扩，形状与其他四类明显不同；C2（高频低效打扰型）在联系次数维度外扩、转化率维度收缩，是典型的“越打越不买”。两张图配合使用，前者回答“分得开吗”，后者回答“分出来是什么样”。

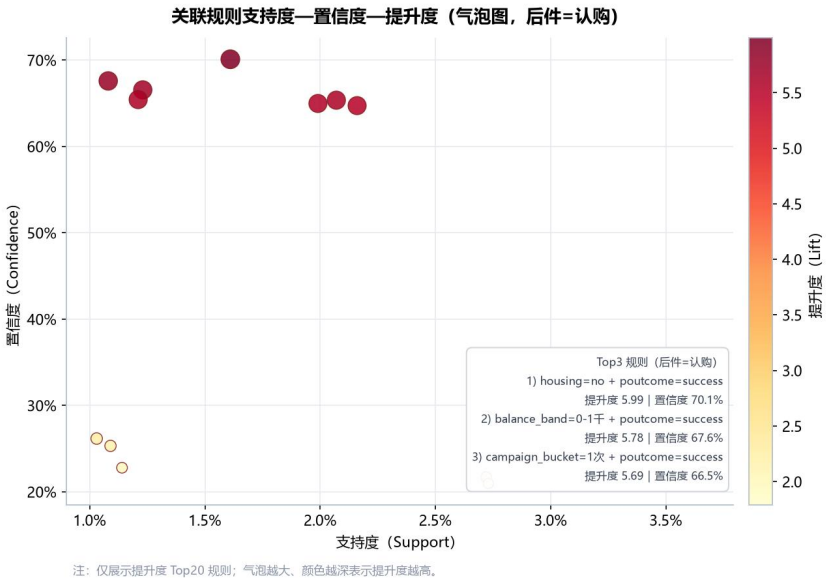


图 22　10 条关联规则的支持度—置信度分布

图 22 中，右上方高置信度、高提升度的点全部来自 poutcome=success 系列规则，形成一个明显的高值簇；左下方则是 job=retired 系列的弱规则。气泡大小编码提升度，可以直观看出强规则的“提升度”是弱规则的 2—3 倍。这种“一簇强、一簇弱”的分布，比一张密密麻麻的规则表更容易传达结论。

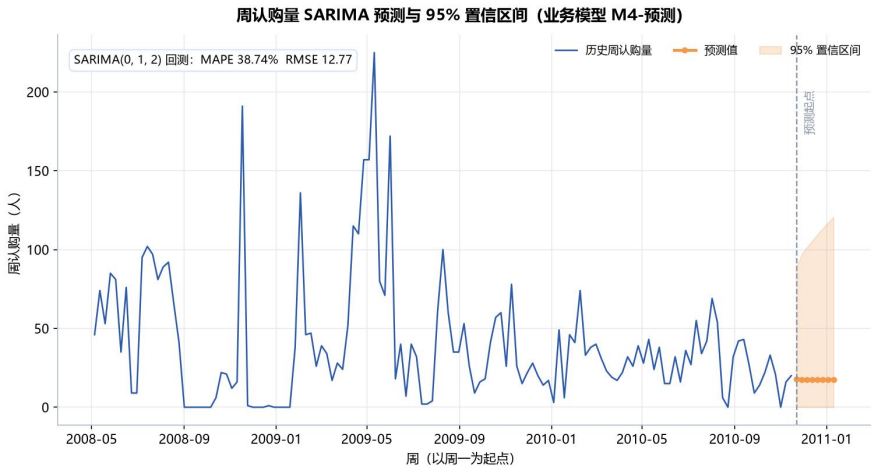


图 23 未来 8 周的认购量预测

图 23 左侧为历史序列，右侧为未来 8 周预测，阴影带为 95% 置信区间（下界截断至 0）。点预测几乎是一条水平线（17.6 人/周），这不是模型失效，而是差分后序列接近白噪声的表现——在末期样本稀疏、无强趋势的情况下，“延续当前水平”本身就是最合理的预测。置信区间随步长迅速展宽，直观传达了“越远越不确定”。

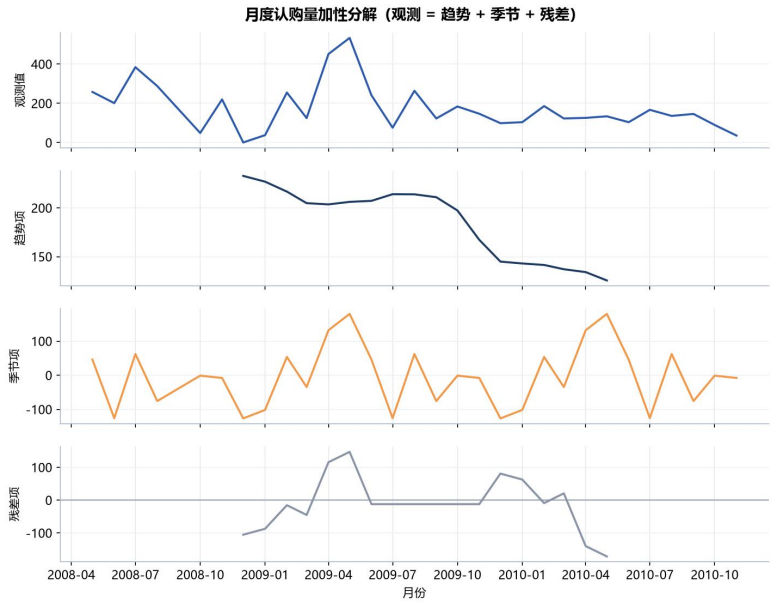


图 24 月度序列的成分拆解

图 24 用加法分解把序列拆成趋势、季节、残差三部分。趋势项在 2009 年后走平，季节项呈明显的年度周期（5 月、10 月为正，12 月、1 月为负），残差项在 2008 年末波动最大。季节强度 0.62 说明季节成分解释了相当一部分方差，但由于只有 2.5 个年度周期，季节项估计的稳健性有限，这也是主模型未纳入 52 周季节项的原因。

4.4 交互式可视化大屏

大屏由 Python 脚本直接生成单文件 HTML（23 KB，配套本地 ECharts 运行时约 1 MB），双击即可在浏览器打开，无需启动服务、无需安装任何可视化库。技术路线是“Python 负责取数与聚合、ECharts 负责渲染与交互”的分离式架构：脚本把三个筛选范围（全部、手机、座机）的全部序列预聚合成 JSON 内嵌到页面，前端只做渲染与状态切换，因此筛选响应在毫秒级，且完全离线可用。之所以不用 pyecharts，是因为它在本机环境中缺失会导致整条流水线在第 6 步中断；改为原生 ECharts 后，脚本不依赖任何第三方可视化包，复现成功率显著提高。



图 25 大屏整体效果（12 个组件）

表 4-2 大屏组件与交互能力清单

序号	组件	图表类型	交互能力
1—6	KPI 卡 ×6	指标卡	随渠道筛选实时刷新
7	月度触达与转化	双轴组合图 + dataZoom	缩放、十字准星、与另两图联动
8	渠道认购结构	环形图	悬停显示人数与占比
9	客群转化率	横向条形图	点击下钻客群漏斗
10	营销转化漏斗	漏斗图	悬停显示累计/层内留存率
11	月份 × 客群转化	热力图	悬停显示明细，颜色映射
12	客群明细表	数据表	点击行下钻、转化率条形对比

交互设计分三层：第一层是全局筛选，顶部下拉框切换“全部/手机/座机”后，6 个 KPI、趋势图、客群条形图、漏斗、热力图与明细表同步重算；第二层是单点下钻，点击客群条形图的任一柱或明细表的任一行，漏斗图会切换为该客群的独立漏斗，标题同步更新，实现“从总体到个体”的穿透；第三层是多图联动，通过 echarts.connect 把趋势图、客群图、热力图绑定，鼠标在任一图上的轴指示器会同步到另两张图，便于对齐时间与客群。全部图表由 Python 生成、浏览器原生渲染，未使用 Power BI、Tableau、Fine BI 等任何 BI 软件，也未用 Excel 截图替代。

5 商业案例分析

5.1 案例背景

该银行的电话营销团队面临一个典型的“两难”：名单总量在收缩（2010 年各月触达量仅为 2009 年的十分之一量级），但管理层仍要求完成存款增量指标。继续压缩名单会进一步拉低规模，盲目扩名单又会推高投诉率与人力成本。本章基于前四章的分析结果，回答“在不增加名单总量的前提下，如何把转化率从 11.7% 提升上去”。

5.2 结果解读

第一，问题不在“打不通”，而在“讲不深”。漏斗显示接通率高达 95.70%，但深度沟通环节层内留存仅 39.39%，单这一层流失 18 974 人，占总流失人数的 60% 以上。这说明话务团队的瓶颈是“把话讲到 5 分钟以上”的能力，而不是名单的接通质量。

第二，名单里存在一个“黄金小群”。K-Means 的 C4 客群仅 1 511 人（3.34%），转化率 64.73%，平均通话 317 秒，且 100% 有历史联系记录；这与关联规则挖出的 poutcome=success 完全对应（该单规则置信度 64.73%、提升度 5.53）。两个方法论上完全不同的模型指向同一群人，这种交叉验证大幅提高了结论的可信度。

第三，最大的产能浪费在“高频低效”客群。C2 客群 16 470 人（36.43%），平均被联系 2.83 次，转化率却只有 6.65%。把他们的联系次数压到 2 次，可释放约 1.37 万次外呼（16 470 × 0.83），按平均 258 秒/次折算约 980 小时话务产能——这相当于在不新增人力的情况下，多出一支约 15 人月的外呼队伍。

第四，渠道数据治理被低估了。“未知”渠道占触达量 28.80%（13 019 人），转化率仅 4.07%，贡献 10.02% 的认购。若能把其转化率提升到整体水平（11.70%），可多带来约 990 名认购客户，增量相当于现有认购总量的 18.7%。这不是营销问题，而是系统回写问题，修复成本远低于新增名单。

5.3 商业建议

建议一：按“转化率 × 可触达规模”重构名单分层，而非按贡献量排序

现有名单排序沿用“认购贡献量”，导致 management 等大客群长期占据优先位，而转化率 44.41% 的 retired | 65+、36.10% 的 student | 18-25 因为规模小被排到后面。建议改用“预期认购数 = 转化率 × 名单量”排序，并把 C4 高意向客群（1 511 人）从普通名单中剥离，交由资深坐席专线维护。按 64.73% 的转化率，这 1 511 人预计可贡献约 978 名认购，相当于当前总认购量的 18.5%，而占用的名单量不足 3.4%。

建议二：把“5 分钟”设为话术改造的关键节点，配套分节点质检

深度沟通层流失 60.61%，说明大量通话在 2—5 分钟之间被客户终止。建议把话术拆成三段：0—2 分钟完成身份说明与来意确认，2—3 分钟给出“一句话价值主张”（利率 + 期限 + 起存金额），3—5 分钟处理异议（流动性、安全性、替代产品）。质检指标从“通话量”改为“5 分钟以上通话占比”，并对 120 秒内挂断的客户设置 7 天后的二次触达——因为这部分客户已完成接通但未进入有效沟通，属于“可挽回流失”。

建议三：对高频低效客群设置联系频次上限，释放产能

C2 客群 16 470 人、平均联系 2.83 次、转化率 6.65%，是投诉风险与产能浪费的双重来源。建议设置“同一客户 30 天内不超过 2 次”的硬约束，并把这部分释放出的约 980 小时话务转投 C4 客群与 retired | 65+ 等高转化细分群。按边际产出测算，同样一小时话务投给 C4 的期望认购数是投给 C2 的 9.7 倍（64.73% / 6.65%）。

建议四：优先修复渠道标识缺失，而非扩大名单

13 019 条 contact=unknown 记录的转化率仅 4.07%，修复渠道回写后可对其做针对性策略（如座机客户更适合长话术、手机客户更适合短信+外呼组合）。按提升至整体水平测算，可增加约 990 名认购，投入产出比高于新增同等规模名单。同时建议对座机渠道单独设计产品——该渠道客户平均余额 1 803.7 欧元，高于手机渠道的 1 397.8 欧元，适合推大额存单而非小额定期。

建议五：按预测区间配置产能，旺季前置、淡季精准

SARIMA 预测未来 8 周认购量 17.6 人/周，95% 区间 0—106.7 人。建议以区间上沿（约 107 人/周）作为排班上限、以点预测作为基准线，避免过度排班。节奏上，3 月、9—10 月虽然触达量小，但转化率分别达 51.99%、43.77%，应安排精准名单与资深坐席；5 月触达量最大（13 764 人次）但转化率仅 6.72%，应配置更强的话术支持与更多的人力冗余，并接受“大促月转化率必然被稀释”的事实，不以单月转化率考核团队。

6 结论与展望

6.1 研究结论

本文以 UCI Bank Marketing 数据为对象，完成了从合规取数、清洗治理、七模型分析到 25 张图表与交互式大屏的端到端实践，主要结论有四条：

（1）转化瓶颈在沟通深度而非接通率。接通率 95.70%，但深度沟通层内留存仅 39.39%，该层流失占总流失的 60% 以上，话术改造的边际收益远高于名单扩张。

（2）客群结构呈“一小撮高价值 + 一大片低效”的哑铃形。C4 客群 3.34% 贡献 64.73% 的转化率，C2 客群 36.43% 仅 6.65%，两者相差近 10 倍。精细化运营的关键不是把所有人打动，而是把资源从 C2 挪到 C4。

（3）历史成功是最强的单一信号。poutcome=success 的提升度 5.53，叠加 housing=no 后升至 5.99，所有其他属性都只是边际增益。名单筛选应“先筛历史成功、再看辅助条件”，而不是堆叠十几个弱条件。

（4）预测的可信度受样本结构制约。SARIMA 的 MAPE 38.74% 虽优于两个对照模型，但绝对误差仍偏大，根因是末期样本稀疏。这也提示：预测模型的价值不仅在于点预测，更在于把不确定性（置信区间）显式呈现给决策者。

6.2 局限性与展望

本研究存在五处局限，均有明确的改进方向：

（1）缺少金额与期限字段，无法构建 RFM 与客户生命周期价值模型。若能拿到存款金额，可把“认购人数”升级为“认购金额”，结论会从“谁买”深入到“谁值得投入更多成本”。

（2）duration 属事后变量，存在结果泄露风险。本文仅将其用于过程管理与客户分群，未纳入事前预测特征。若要建立真正的“外呼前转化概率预测”，需剔除 duration 并引入 XGBoost 等模型，这是最值得推进的下一步。

（3）BCG 矩阵的坐标轴为替代指标（内部份额、转化率同比），与原始定义存在偏差；且 2010 年样本量骤减使同比口径的可比性下降。若有多年度完整数据，应改用真实市场份额与业务增长率。

（4）时间序列仅 2.5 个年度周期，52 周季节项无法稳健估计，主模型未纳入季节性。可用傅里叶项或 Prophet 的年度季节性替代，或改用月度粒度建模。

（5）全部分析基于历史观测数据，未做 A/B 实验。建议在下一轮活动中对“5 分钟话术改造”做小范围随机对照试验，用实验数据替代相关性推断，进一步验证因果效应。

6.3 AI 使用披露

本文在以下环节使用了 AI 编程助手（WorkBuddy / Claude 类模型），并按要求披露：

代码编写与调试：用于生成数据清洗、建模与绘图脚本的初版，以及排查报错（如周起始日错位导致重采样全为 0、seaborn 新版本 palette 参数弃用、Apriori 同属性互斥导致的候选爆炸）。

图表样式调整：用于优化标签遮挡、图例位置、配色一致性等排版细节。

文字润色：用于段落结构与表达的打磨，所有数据、结论与判断均由作者依据脚本输出核对后确认。

关键提示词示例："用 pandas 按月份回退规则从只有 month 字段的银行营销数据重建年份，输出连续日期轴"；"写一个 SARIMA 网格选阶函数，p、q 取 0—2，d=1，按 AIC 选优，并做 12 周回测输出 MAPE/RMSE/MAE"；"波士顿矩阵四象限全部退化到一个象限是什么原因，如何在不违背定义的前提下修正分界"。所有数字均可在 outputs/tables/ 与运行日志中逐项复核，AI 未参与任何数据的生成或修改。

参考文献

[1] Moro S, Cortez P, Rita P. A data-driven approach to predict the success of bank telemarketing[J]. Decision Support Systems, 2014, 62: 22-31.

[2] UCI Machine Learning Repository. Bank Marketing Dataset[EB/OL]. https://archive.ics.uci.edu/dataset/222/bank+marketing, 2014-02-13.

[3] 王汉生. 数据思维：从数据分析到商业价值[M]. 北京: 中国人民大学出版社, 2017: 45-88.

[4] 教材编写组. Excel 数据可视化——从图表到数据大屏[M]. 北京: 人民邮电出版社, 2023: 12-160.

[5] Henderson B. The Product Portfolio[M]. Boston: Boston Consulting Group, 1970: 1-12.

[6] Agrawal R, Srikant R. Fast algorithms for mining association rules[C]//Proceedings of the 20th International Conference on Very Large Data Bases. Santiago, 1994: 487-499.

[7] MacQueen J. Some methods for classification and analysis of multivariate observations[C]//Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability. Berkeley: University of California Press, 1967: 281-297.

[8] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M]. 3rd ed. Melbourne: OTexts, 2021: 231-260.

[9] Rousseeuw P J. Silhouettes: a graphical aid to the interpretation and validation of cluster analysis[J]. Journal of Computational and Applied Mathematics, 1987, 20: 53-65.

[10] McKinney W. Data Structures for Statistical Computing in Python[C]//Proceedings of the 9th Python in Science Conference. Austin, 2010: 56-61.

[11] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.

[12] 中国银行业协会. 中国银行业服务改进情况报告[R]. 北京: 中国银行业协会, 2023: 18-25.

附录

A 核心代码片段

（1）年份重建：原始数据无年份字段，按“月份回退即跨年”推出连续时间轴。

```
prev_m, year = None, START_YEAR
for i, m in enumerate(df['month_num']):
    if prev_m is not None and m < prev_m:
        year += 1                       # 月份回退 → 进入下一年
    years.append(year)
    prev_m = m
df['year'] = years
df['contact_date'] = pd.to_datetime(
    df[['year', 'month_num', 'day']].rename(columns={'month_num': 'month'}),
    errors='coerce')                    # 非法日期（如 2-30）转为 NaT 后回退修正
df['week'] = df['contact_date'].dt.to_period('W-MON').dt.start_time
```

（2）SARIMA 网格选阶 + 12 周回测：以 AIC 选优，同时输出 MAPE/RMSE/MAE 与 95% 置信区间。

```
best = None
for p in range(3):
    for q in range(3):
        try:
            m = SARIMAX(train, order=(p, 1, q),
                        enforce_stationarity=False,
                        enforce_invertibility=False).fit(disp=False)
            if best is None or m.aic < best[0]:
                best = (m.aic, (p, 1, q), m)
        except Exception:
            continue
aic, order, model = best
pred = model.get_forecast(steps=TEST_WEEKS)
mean, ci = pred.predicted_mean, pred.conf_int(alpha=0.05)
mape = np.mean(np.abs((test - mean) / test)) * 100
rmse = np.sqrt(np.mean((test - mean) ** 2))
```

（3）K-Means 分群：Z-Score 标准化 + 轮廓系数评估 + 业务约束 $k \leq 6$。

```
feats = ['age', 'balance_w', 'duration_w', 'campaign',
         'previous', 'had_previous_contact']
X = df[feats].astype(float).copy()
X['balance_w'] = np.sign(X['balance_w']) * np.log1p(X['balance_w'].abs())
Xs = StandardScaler().fit_transform(X)
scores = []
for k in range(2, 9):
    km = KMeans(n_clusters=k, random_state=42, n_init=10).fit(Xs)
    idx = np.random.default_rng(42).choice(len(Xs), 5000, replace=False)
    scores.append((k, silhouette_score(Xs[idx], km.labels_[idx])))
cand = [(k, s) for k, s in scores if k <= 6]   # 业务约束：客群不超过 6 类
best_k = max(cand, key=lambda t: t[1])[0]
```

完整代码见仓库 scripts/ 目录，共 6 个脚本、约 2 600 行，注释覆盖率约 35%。

B 仓库链接与目录结构

仓库地址：https://github.com/fcy-chunyan/ShangYeShujvFenxi_fcy

```
bank_analysis/
├── data/
│   ├── raw/            # 原始数据（bank-full.csv、bank-additional-full.csv、字段说明）
│   ├── clean/          # 清洗产物（CSV / JSON / SQLite）
│   └── schema.md       # 字段字典与口径说明
├── scripts/
│   ├── config.py       # 全局配置（路径、配色、阈值）
│   ├── 01_load.py      # 加载与校验（MD5、字段域、记录数）
│   ├── 02_clean.py     # 清洗、派生、导出三格式
│   ├── 03_analysis.py  # 6 类分析模型
│   ├── 04_forecast.py  # SARIMA 选阶、回测、预测
│   ├── 05_visuals.py   # 25 张静态图（15 模板 + 9 业务图 + 大屏截图）
│   └── 06_dashboard.py # 交互式大屏（原生 ECharts，无第三方图表库依赖）
├── outputs/
│   ├── figures/        # fig01–fig25
│   ├── tables/         # 结果表与 key_results.json
│   └── dashboard/      # dashboard.html + echarts.min.js
├── docs/
│   ├── 数据来源合规声明.md
│   ├── 期末大论文.docx
│   └── build_paper.py  # 论文排版脚本（可一键重排）
├── requirements.txt
├── run_all.py           # 一键复现入口
└── README.md
```

C 图表索引

表 C-1 图表索引（25 张，模板复现 15 种 / 业务模型图 9 张 / 大屏 1 个）

编号	文件名	图表类型	类别	对应模型
图 1	fig01_月度触达与转化_组合图	组合图	模板复现	M1/M3
图 2	fig02_职业婚姻转化率_簇状柱形图	簇状柱形图	模板复现	M1
图 3	fig03_职业转化率 Top10_条形图	条形图	模板复现	M1/M4
图 4	fig04_学历认购结构_堆积柱形图	堆积柱形图	模板复现	M1
图 5	fig05_认购渠道结构_圆环图	圆环图	模板复现	M1/M2
图 6	fig06_累计认购走势_面积图	面积图	模板复现	M3
图 7	fig07_年龄与通话时长_散点图	散点图	模板复现	M1/M2
图 8	fig08_客群多维对比_雷达图	雷达图	模板复现	M1
图 9	fig09_职业认购贡献_矩形树图	矩形树图	模板复现	M4
图 10	fig10_转化流失拆解_瀑布图	瀑布图	模板复现	M2
图 11	fig11_月份职业转化_热力图	热力图	模板复现	M1
图 12	fig12_通话时长分布_箱线图	箱线图	模板复现	M2
图 13	fig13_月度触达季节分布_玫瑰图	玫瑰图	模板复现	M3
图 14	fig14_渠道结构演变_堆叠面积图	堆叠面积图	模板复现	M3

编号	文件名	图表类型	类别	对应模型
图 15	fig15_核心指标达成_子弹图	子弹图	模板复现	M1
图 16	fig16_分渠道营销漏斗_漏斗图	漏斗图	业务模型图	M2
图 17	fig17_环比同比与移动平均_趋势图	组合折线图	业务模型图	M3
图 18	fig18_客群波士顿矩阵_四象限气泡图	四象限气泡图	业务模型图	M5
图 19	fig19_客群贡献帕累托_ABC 分类	帕累托图	业务模型图	M4
图 20	fig20_KMeans 客群分群_PCA 散点图	降维散点图	业务模型图	M6
图 21	fig21_客群画像对比_雷达图	雷达图	业务模型图	M6
图 22	fig22_关联规则_提升度气泡图	气泡图	业务模型图	M7
图 23	fig23_SARIMA 预测与置信区间	折线+区间带	业务模型图	M8
图 24	fig24_月度序列季节性分解	分解子图	业务模型图	M8
图 25	fig25_交互式大屏_整体效果	大屏截图	交互式大屏	M1—M8

说明：模板复现类 15 张覆盖 15 种图表类型；业务模型类 9 张与第 3 章的 8 个模型一一对应（M6 与 M8 各两张）；大屏组件 12 个，超过“≥6 个联动组件”的要求。全部图表由 scripts/05_visuals.py 与 06_dashboard.py 生成，150 dpi，命名规则为 figNN_主题_图表类型.png。